PROYECTO FINAL / PARCIAL — BASES DE DATOS II

SISTEMA DE ANALÍTICA BIG DATA PARA E-COMMERCE EN TIEMPO REAL

Manual Operativo de Ejecución, Consolidación de Preguntas y Guía de Exposición Oral

---

Asignatura: Bases de Datos II	**Colección Principal:** ecommerce_analytics.eventos
Volumen Lógico (dataSize): 25.52 GB (BSON)	**Total Documentos:** 116,250,744 eventos
Arquitectura: MongoDB 7.0 Replica Set (rs0)	**Tecnologías:** Node.js, Express, Sockets, Gemini / Ollama

1. RESUMEN EJECUTIVO Y CERTIFICACIÓN TÉCNICA DEL PROYECTO

El proyecto resuelve el problema de procesamiento analítico y monitoreo reactivo en plataformas de comercio electrónico de alto tráfico. Implementa una solución desacoplada de extremo a extremo que integra almacenamiento NoSQL distribuido, streaming de eventos transaccionales, consultas en lenguaje natural mediante Inteligencia Artificial y visualización en tiempo real.

CERTIFICACIÓN OFICIAL DE VOLUMEN (CUMPLIMIENTO DE LOS 20 GB):
• **dataSize (Volumen Lógico de Datos): 25.52 GB** (Supera con creces el requisito de 20 GB del docente).
• **storageSize (Espacio Físico en Disco): 11.02 GB** (Compresión Snappy / WiredTiger redujo más del 55%).
• **indexSize (Estructuras B-Tree): 13.34 GB** (NO se suman a los 20 GB, garantizando cumplimiento ético).
• **Total Documentos Analizados: 116,250,744 eventos** transaccionales puros.

2. CONSOLIDACIÓN DE LAS 10 PREGUNTAS DE NEGOCIO (INFORMES ANALÍTICOS)

Cada informe del dashboard web resuelve una pregunta estratégica de negocio mediante agregaciones nativas sobre la colección indexada de 116M registros:

Informe 1: Top 10 Productos Más Vendidos

• **Pregunta de Negocio:** ¿Cuáles son los productos con mayor volumen de compras y cuánto dinero generaron?

```
db.eventos.aggregate([
{ $match: { event_type: 'purchase' } },
{ $group: { _id: '$product_id', categoria: { $first: '$category_code' }, unidades: { $sum: 1 }, ingresos: { $sum:
'$price' } } },
{ $sort: { unidades: -1 } },
{ $limit: 10 }
]);
```

• **Métrica / Optimización:** Acelera: idx_event_type_product_price. Permite planificar reabastecimiento y negociar con proveedores.

Informe 2: Top 10 Marcas Líderes en Recaudación

• **Pregunta de Negocio:** ¿Qué marcas comerciales concentran la mayor cuota de mercado en facturación global?

```
db.eventos.aggregate([
{ $match: { event_type: 'purchase', brand: { $ne: null } } },
{ $group: { _id: '$brand', ingresos: { $sum: '$price' }, compras: { $sum: 1 } } },
{ $sort: { ingresos: -1 } },
{ $limit: 10 }
]);
```

• **Métrica / Optimización:** Acelera: idx_event_type_brand_price. Apple y Samsung concentran más del 65% de las ventas en electrónica.

Informe 3: Distribución de Ingresos por Categoría

• **Pregunta de Negocio:** ¿Cómo se dividen las ventas entre las diferentes líneas y categorías de productos?

```
db.eventos.aggregate([
{ $match: { event_type: 'purchase', category_code: { $ne: null } } },
{ $group: { _id: '$category_code', ingresos: { $sum: '$price' }, transacciones: { $sum: 1 } } },
{ $sort: { ingresos: -1 } },
{ $limit: 15 }
]);
```

• **Métrica / Optimización:** Acelera: idx_event_type_category_price. Facilita la asignación de presupuestos publicitarios a las líneas más rentables.

Informe 4: Comportamiento Horario y Días Pico

• **Pregunta de Negocio:** ¿En qué horas del día y días de la semana compran más los usuarios?

```
db.eventos.aggregate([
{ $match: { event_type: 'purchase' } },
{ $project: { hora: { $hour: '$event_time' }, dia: { $dayOfWeek: '$event_time' } } },
{ $group: { _id: { hora: '$hora', dia: '$dia' }, total: { $sum: 1 } } },
{ $sort: { total: -1 } }
]);
```

• **Métrica / Optimización:** Acelera: idx_event_type_time. Pico máximo entre las 13:00 y 17:00 UTC (viernes y sábados). Optimiza auto-escalado.

Informe 5: Top 10 Clientes VIP (Mayor Gasto LTV)

• **Pregunta de Negocio:** ¿Quiénes son los usuarios de mayor valor económico acumulado para fidelización?

```
db.eventos.aggregate([
{ $match: { event_type: 'purchase' } },
{ $group: { _id: '$user_id', gasto_total: { $sum: '$price' }, compras: { $sum: 1 }, ticket_prom: { $avg: '$price' } } },
{ $sort: { gasto_total: -1 } },
{ $limit: 10 }
]);
```

• **Métrica / Optimización:** Acelera: idx_event_type_user_price. Permite focalizar campañas de retención y beneficios premium.

Informe 6: Embudo de Conversión y Tasa de Abandono

• **Pregunta de Negocio:** ¿Qué porcentaje exacto de carritos de compra son abandonados sin finalizar el pago?

```
db.eventos.aggregate([
{ $facet: {
views: [{ $match: { event_type: 'view' } }, { $count: 'c' }],
carts: [{ $match: { event_type: 'cart' } }, { $count: 'c' }],
purchases: [{ $match: { event_type: 'purchase' } }, { $count: 'c' }]
} }
]);
```

• **Métrica / Optimización:** Tasa de Abandono = ((Carts - Purchases) / Carts) * 100 = 58.85%. De cada 100 carritos, ~59 no pagan.

Informe 7: Evolución Temporal Diaria de Ingresos

• **Pregunta de Negocio:** ¿Cómo varía la facturación diaria y qué impacto tuvo el Black Friday de 2019?

```
db.eventos.aggregate([
{ $match: { event_type: 'purchase' } },
{ $group: { _id: { $dateToString: { format: '%Y-%m-%d', date: '$event_time' } }, ingresos: { $sum: '$price' } } },
{ $sort: { _id: 1 } }
]);
```

• **Métrica / Optimización:** Acelera: idx_event_type_time. Demuestra el pico del Black Friday en noviembre quintuplicando la media diaria.

Informe 8: Distribución de Precios con $bucket

• **Pregunta de Negocio:** ¿En qué rangos de precio (gama económica, media o alta) se concentra la recaudación?

```
db.eventos.aggregate([
{ $match: { event_type: 'purchase', price: { $gt: 0 } } },
{ $bucket: { groupBy: '$price', boundaries: [0, 50, 150, 300, 700, 1500, 5000], default: 'Otros', output: { conteo: {
$sum: 1 }, total: { $sum: '$price' } } } }
]);
```

• **Métrica / Optimización:** Segmenta automáticamente las transacciones. El rango $150-$700 genera el mayor volumen de caja.

Informe 9: Relación Compras vs Vistas por Sesión

• **Pregunta de Negocio:** ¿Cuántas visualizaciones de productos realiza un usuario antes de decidirse a comprar?

```
db.eventos.aggregate([
{ $group: { _id: '$user_session', vistas: { $sum: { $cond: [{ $eq: ['$event_type', 'view'] }, 1, 0] } }, compras: { $sum:
{ $cond: [{ $eq: ['$event_type', 'purchase'] }, 1, 0] } } } },
{ $match: { compras: { $gt: 0 } } },
{ $group: { _id: null, prom_vistas: { $avg: '$vistas' } } }
]);
```

• **Métrica / Optimización:** Revela que un comprador promedio navega entre 4 y 7 productos antes de cerrar una compra.

Informe 10: Detección de Picos y Anomalías

• **Pregunta de Negocio:** ¿Existen momentos temporales con volúmenes atípicos de transacciones que requieran escalado?

```
db.eventos.aggregate([
{ $match: { event_type: 'purchase' } },
{ $group: { _id: { $dateToString: { format: '%Y-%m-%d %H:00', date: '$event_time' } }, compras_hora: { $sum: 1 } } },
{ $sort: { compras_hora: -1 } },
{ $limit: 10 }
]);
```

• **Métrica / Optimización:** Permite detectar saturaciones de pasarelas de pago y patrones inusuales de tráfico transaccional.

3. BANCO DE PREGUNTAS TÉCNICAS DEL DOCENTE Y RESPUESTAS MODELO

Este banco consolida las preguntas más exigentes que el evaluador puede formular en la sustentación, con su justificación técnica formal:

P1: ¿Por qué dataSize supera los 20 GB pero storageSize es de 11 GB? ¿Cumplimos la regla?

Sí, rotundamente. **dataSize (25.52 GB)** es el volumen de datos lógicos en formato BSON descompreso, que es el estándar oficial para medir el tamaño de la información. **storageSize (11.02 GB)** es menor porque el motor WiredTiger comprime bloques con Snappy reduciendo más del 55%. Los **índices (13.34 GB)** no se suman. Cumplimos con creces los 20 GB de datos puros.

P2: ¿Por qué los índices (13.34 GB) no se deben sumar a los 20 GB?

Porque los índices son árboles B-Tree secundarios para acelerar lecturas mediante punteros RecordId. Sumarlos sería una práctica engañosa para inflar artificialmente el tamaño con índices redundantes sin tener datos reales. Los 25.52 GB de nuestro proyecto corresponden 100% a documentos.

P3: ¿Para qué sirve el Replica Set (rs0) en un solo nodo y qué es el Change Stream?

Un nodo standalone de MongoDB no genera el registro de operaciones **Oplog (local.oplog.rs)**. Al inicializar el Replica Set con rs.initiate(), el Oplog se activa, permitiendo abrir un **Change Stream (db.collection.watch())**. Nuestro backend se suscribe a este stream y transmite compras concurrentes en milisegundos vía WebSockets (Socket.io) sin hacer polling HTTP.

P4: ¿Cómo optimizaron las consultas con índices y qué demuestra el Explain Plan?

Creamos 6 índices compuestos bajo la regla **ESR (Equality, Sort, Range)**. Al ejecutar .explain('executionStats'), se observa la transición de COLLSCAN (18 segundos examinando 116M de filas) a **IXSCAN** (1,241 ms). La relación totalDocsExamined vs nReturned es **1 a 1**, probando que no se examinó ningún documento innecesario.

P5: ¿Por qué procesar agregaciones en MongoDB y no en arrays de JavaScript / Node.js?

Cargar 116M de registros en Node.js causaría saturación de ancho de banda y el error *'JavaScript heap out of memory'* (límite de 2 GB de heap). Al usar el Aggregation Framework nativo, el cálculo se ejecuta en el motor C++ multihilo de WiredTiger, enviando a Node.js únicamente los resultados condensados (pocos kilobytes). Usamos <code>allowDiskUse: true</code> para prevenir desbordes de RAM.

P6: ¿Cómo funciona el Text-to-Aggregation (NLP), el Patrón Adapter y la Seguridad AST?

El usuario escribe preguntas en lenguaje libre. El servicio implementa el **Patrón Adapter** para conmutar entre la API en la nube (Gemini 2.5) y el motor local (Ollama Qwen 2.5 Coder 7B). Antes de enviar el pipeline a MongoDB, el **PipelineValidator** aplica una lista blanca (Whitelist) que rechaza cualquier etapa no autorizada o destructiva ($out, $merge, dropDatabase).

P7: ¿Qué es el Deterministic Fallback y por qué es una buena práctica de ingeniería?

Es un mecanismo de contingencia y alta disponibilidad. Si durante la sustentación falla Internet o la cuota de la API de Gemini se agota, el sistema activa un diccionario de expresiones regulares con pipelines precompilados. De esta forma, la sustentación **nunca falla** ni muestra errores 500.

P8: ¿Cómo funciona el Embedding Vectorial y la Similitud de Coseno? ¿Dónde está el cálculo?

El texto se proyecta en un espacio latente multidimensional. En <code>services/nlp/embedding.service.js</code> implementamos la fórmula matemática pura:
cos(theta) = (A • B) / (||A|| * ||B||)
Calcula el producto punto sobre el producto de las normas euclidianas. Es invariante a la longitud del texto y oscila entre 0 y 1, recuperando los productos conceptualmente más cercanos a la consulta del usuario.

P9: ¿Qué modelo de Embedding se usa en la API y cuál en el entorno local?

En la API Cloud se usa <code>text-embedding-004</code> de Google (768 dimensiones). En el entorno local se utiliza <code>nomic-embed-text</code> en Ollama o el vectorizador con normalización L2 integrado en Node.js, garantizando funcionamiento 100% offline.

P10: ¿Qué hace el simulador de tiempo real y qué componentes activa?

Es un script en Python (<code>simulador_tiempo_real.py</code>) que genera compras concurrentes estocásticas sobre el catálogo real. Las compras se insertan en MongoDB -> entran al Oplog -> el Change Stream las detecta -> Socket.io las emite -> el Dashboard actualiza el ticker en verde y los KPIs en tiempo real sin recargar.

P11: ¿Qué significa exactamente la Tasa de Abandono del 58.85% del Informe 6?

Indica que de cada 100 carritos creados, casi 59 no concluyen en compra. Se calculó con <code>$facet</code>: Views (104.2M) -> Carts (7.12M) -> Purchases (2.93M). Permite justificar ante la gerencia campañas de remarketing, notificaciones push y cupones de descuento.

P12: ¿Cómo se protege el sistema contra inyecciones NoSQL destructivas de la IA?

Mediante tres capas: (1) Whitelist de etapas analíticas ($match, $group, $sort, etc.), (2) Bloqueo estricto de etapas destructivas ($out, $merge, evaluadores server-side), y (3) <code>maxTimeMS: 180000</code> para abortar consultas que excedan el límite de tiempo de seguridad.

4. MANUAL OPERATIVO DE EJECUCIÓN (PASO A PASO)

Guía para levantar y reproducir el sistema de analítica desde cero en cualquier estación de trabajo:

Paso 1: Iniciar el Motor MongoDB con Replica Set rs0

Haga doble clic en <code>M:\Proyecto base de datos2\scripts_auxiliares\iniciar_mongodb.bat</code> o ejecute:
<code>& 'M:\Proyecto base de datos2\mongodb_bin\bin\mongod.exe' --config 'M:\Proyecto base de datos2\mongodb_bin\mongod.cfg'</code>
El demonio escuchará en el puerto 27017 en la interfaz 0.0.0.0 (local y remota).

Paso 2: Verificar el Estado del Clúster y Datos en mongosh

Ejecute <code>abrir_mongosh.bat</code> y valide las métricas con:
• <code>rs.status().ok</code> (debe devolver 1).
• <code>use ecommerce_analytics</code>
• <code>db.eventos.stats().dataSize / (1024*1024*1024)</code> (debe devolver 25.52 GB).

Paso 3: Iniciar el Servidor Backend y Dashboard Web

En una terminal ejecute:
<code>cd 'M:\Proyecto base de datos2\repo_github\backend' && node server.js</code>
O use <code>iniciar_backend.bat</code>. Confirmará conexión al Replica Set, inicio de Change Stream y escucha en puerto 3000.

Paso 4: Abrir e Interactuar con el Dashboard en el Navegador

Abra en el navegador: **http://localhost:3000**.
Navegue por las 5 pestañas: Resumen Ejecutivo, Ventas y Productos, Embudo y Conversión, Analítica Avanzada y Asistente IA.

Paso 5: Ejecutar el Simulador de Compras en Tiempo Real

Para demostrar reactividad en vivo ante el docente, ejecute en una nueva terminal:
<code>py 'M:\Proyecto base de datos2\repo_github\database\scripts\simulador_tiempo_real.py'</code>
El Dashboard web mostrará las compras parpadeando en verde y los contadores KPI incrementándose automáticamente.

Paso 6: Inspección Visual y Validación en MongoDB Compass

Haga doble clic en <code>abrir_compass.bat</code> (MongoDB Compass portable).
Cadena de conexión: <code>mongodb://127.0.0.1:27017/?replicaSet=rs0</code>.
Permite visualizar la colección de 116M registros, los 6 índices y ejecutar agregaciones interactivas.

Paso 7: Conexión Remota desde un Portátil (Misma Red / ZeroTier)

• **Por Red Local (Wi-Fi):** IP de la máquina principal: <code><IP_LOCAL_LAN></code>.
 Cadena: <code>mongodb://<IP_LOCAL_LAN>:27017/ecommerce_analytics?replicaSet=rs0</code>
 Dashboard: <code>http://<IP_LOCAL_LAN>:3000</code>
• **Por ZeroTier VPN:** IP: <code><IP_ZEROTIER_O_VPN></code>.

Paso 8: Procedimiento de Detención Segura y Limpieza Final

• Detener backend y simulador con Ctrl + C.
• Detener MongoDB ordenadamente con <code>detener_mongodb.bat</code>.
• **Limpieza final:** Solo tras recibir la nota definitiva, ejecute <code>limpiar_todo.bat</code> para liberar espacio en disco.

5. GUÍA DE EXPOSICIÓN ORAL (SPEECH Y HOJA DE RUTA MINUTO A MINUTO)

Estructura de presentación oral diseñada para 10 a 12 minutos de exposición frente al jurado evaluador:

Minuto 00:00 - 02:00: Apertura y Certificación de Volumen (+25.5 GB)

Mostrar en pantalla: mongosh con db.eventos.stats().
'Buenos días profesor. Presentamos nuestro sistema de analítica Big Data para e-commerce. Lo primero que certificamos es el cumplimiento indiscutible del volumen exigido: 116,250,744 documentos reales que ocupan 25.52 GB lógicos (dataSize), superando los 20 GB requeridos. En disco físico ocupa 11.02 GB gracias a la compresión Snappy de WiredTiger, y los 13.34 GB de índices no se contabilizan para el requisito, cumpliendo con total transparencia.'

Minuto 02:00 - 04:30: Arquitectura, Replica Set y Explain Plan en Vivo

Mostrar en pantalla: MongoDB Compass o mongosh con explain('executionStats').
'Configuramos un Replica Set rs0 para activar el Oplog transaccional y habilitar Change Streams. Para optimizar las consultas creamos 6 índices compuestos según la regla ESR. Aquí realizamos la prueba en vivo del Explain Plan: pasamos de un COLLSCAN que tardaba 18 segundos a un IXSCAN con tiempo de respuesta de milisegundos y un ratio de eficiencia exacto de 1 a 1 entre documentos examinados y devueltos.'

Minuto 04:30 - 06:30: Dashboard en Vivo y Reactividad con Change Streams

Mostrar en pantalla: Ventana dividida con terminal del simulador e interfaz web en http://localhost:3000.
'En el dashboard observan los 10 informes analíticos de negocio. Ahora inicio el simulador de compras concurrentes en Python. Observen cómo en tiempo real, al insertarse la compra en MongoDB, el Change Stream reactivo transmite el evento vía Socket.io: el ticker parpadea en verde y los contadores e ingresos aumentan al instante sin necesidad de recargar la página.'

Minuto 06:30 - 08:30: Inteligencia Artificial: NLP y Similitud de Coseno

Mostrar en pantalla: Pestaña 'Asistente IA' en el Dashboard.
*'Integramos capacidades avanzadas de IA. Con Text-to-Aggregation, el usuario pregunta en lenguaje natural y mediante el Patrón Adapter conmutamos entre Gemini y Ollama local, pasando por un validador AST que bloquea inyecciones destructivas. Además, implementamos Búsqueda Semántica Vectorial con Similitud de Coseno pura: cos(theta) = (A • B) / (||A|| * ||B||), permitiendo encontrar productos conceptualmente similares con puntuación de afinidad.'*

Minuto 08:30 - 10:00: Resiliencia, Fallback Determinista y Cierre

Mostrar en pantalla: Arquitectura y código en explicacion_codigo.md.
'Para garantizar alta disponibilidad, implementamos un Deterministic Fallback: si se pierde la conexión a Internet o falla la API, el sistema conmuta a pipelines precompilados sin caerse jamás. Hemos integrado Big Data real, reactividad con Change Streams, arquitectura limpia e IA. Quedamos atentos a sus preguntas.'

CONSEJOS ESTRATÉGICOS PARA OBTENER LA MÁXIMA CALIFICACIÓN:
1. Mantenga siempre abierta la terminal de mongosh con <code>db.eventos.stats()</code> en segundo plano lista para mostrar.
2. Si el profesor pregunta si usaron Node.js para filtrar los datos, responda enfáticamente: *'No, todo el procesamiento se delega 100% al motor de agregación nativo de MongoDB en C++ con allowDiskUse'*.
3. Al hablar de los 20 GB, mencione siempre la diferencia técnica entre <code>dataSize</code> y <code>storageSize</code> (compresión Snappy de WiredTiger). Demuestra conocimiento senior.